Bilgisayar Mühendisliği Programında Hazırlanan Bitirme Projesi

MÜZİK TÜRLERİ SINIFLANDIRILMASI VE ÖNERİ SİSTEMİ

TEZ DANIŞMANI : DR. ARZU KAKIŞIM

HAZIRLAYAN : ŞEVVAL YOĞURTCUOĞLU

İÇİNDEKİLER

- Giriş
1. Müzik nedir, türleri nelerdir ?
2. Neden müzik sınıflandırılması yapılıp öneri sunulmalıdır ?
3. Problemin gerçek hayatta görüldüğü alanlar
4. Problemin çözümü adımları
- Deneysel kurulum
1. Veri seti tanıtımı, veri ön işlemesi
2. Sınıflandırma için kullanılan algoritmalar
3. Öneri sistemi
4. Kodun çalışma mantığının açıklanması
- Sonuç
1. Karşılaşılan problemler
2. Geliştirilebilir yanlar
- Kullanıcı ara yüzü

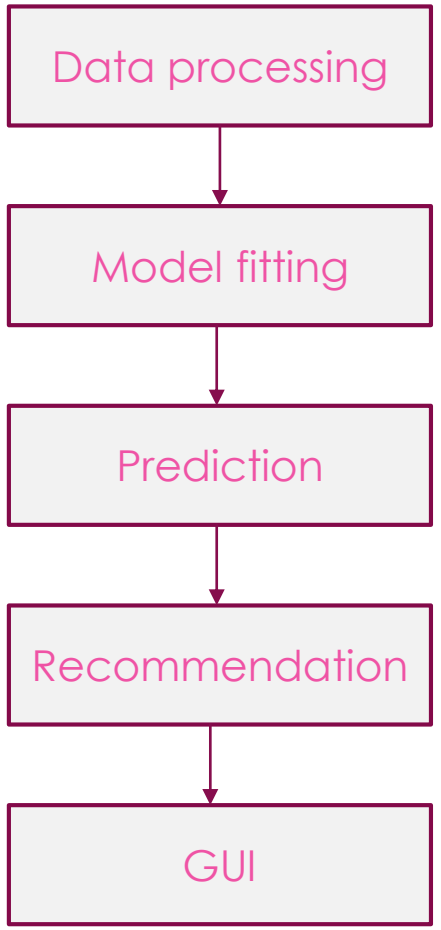

GİRİŞ (INTRODUCTION)

Müzik nedir? , Müzik türleri nelerdir?

- Müzik, sesin biçim ve anlamlı titreşimler kazanmış halidir.

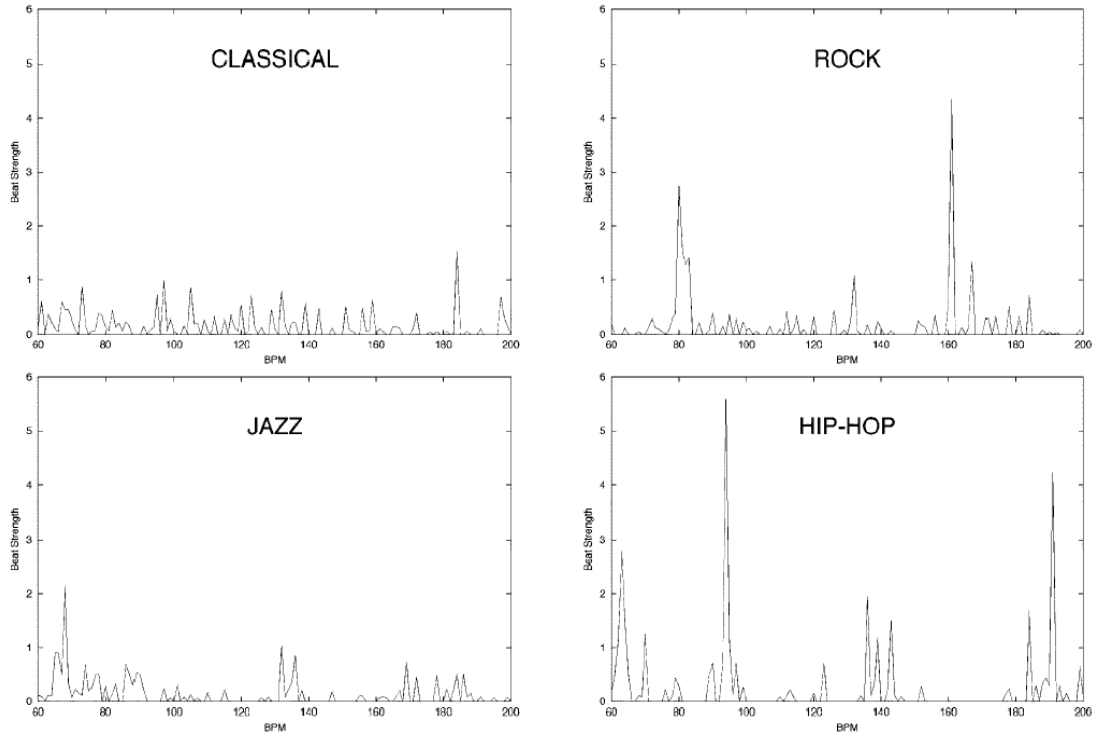

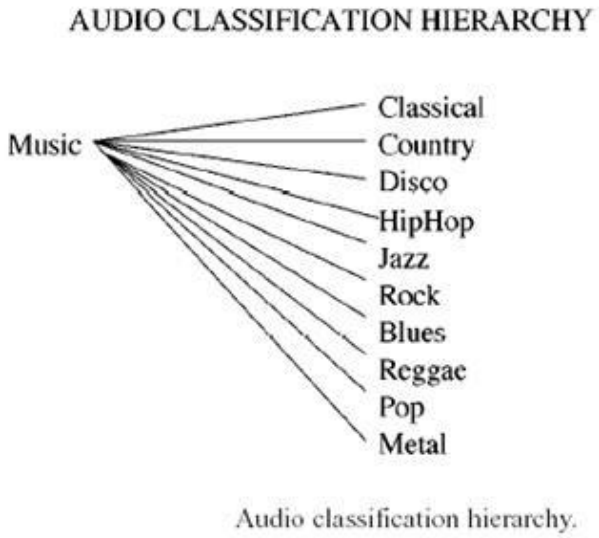

Audio classification hierarchy.

Neden Müzik Sınıflandırılması Yapılmalıdır ? Neden Öneri Sunulmalıdır ?

- Müzik, çoğu insanın günlük hayatında sıkça kullandığı bir sanattır. Bu nedenle müzik hizmetleri insanların sevdikleri müzikleri dinleyebilmeleri için birincil araç haline gelmiştir. Müzik hizmetleri kullanıcıların hareketlerine bakarak onlara kişiselleştirmiş bir deneyim sunarlar. Kullanıcının dinlediği müziklere benzer parçalar önerildiğinde kullanıcı sevdiği tarzda müziklere rahatça erişebilmiş olur.

Problemin Gerçek Hayatta Görüldüğü Alanlar

- Günümüz en popüler müzik hizmetleri ;
  - Spotify 
  - Shazam 
  - Soundcloud 
  - Fizy 

Müşterilerine müzik önerisinde bulunmak için müzik sınıflandırması kullanmaktadır. Müzik türlerinin belirlenmesi bu yöndeki ilk adımdır.

Problemin Çözümü Adımları

- Bu projede makine öğrenmesi ile müzik türlerinin sınıflandırılması ve seçilen müziğe benzer önerilerin sunulması hedeflenmiştir.

Müzik verileri ile ;

1) Pre-processing (Ön işleme) , Feature extraction (öznitelik çıkarımı), feature selection (öznitelik seçimi) uygulanarak veri seti oluşturuldu
2) Makine öğrenmesi algoritmaları kullanılarak müzikler sınıflandırıldı.
3) Performans değerlendirmesi yaparak en iyi algoritma seçildi.
4) Seçilen algoritma ile öneri sistemi geliştirildi.

DENEYSEL KURULUM
(EXPERIMENTAL SETUP)

Kullanılan Veri

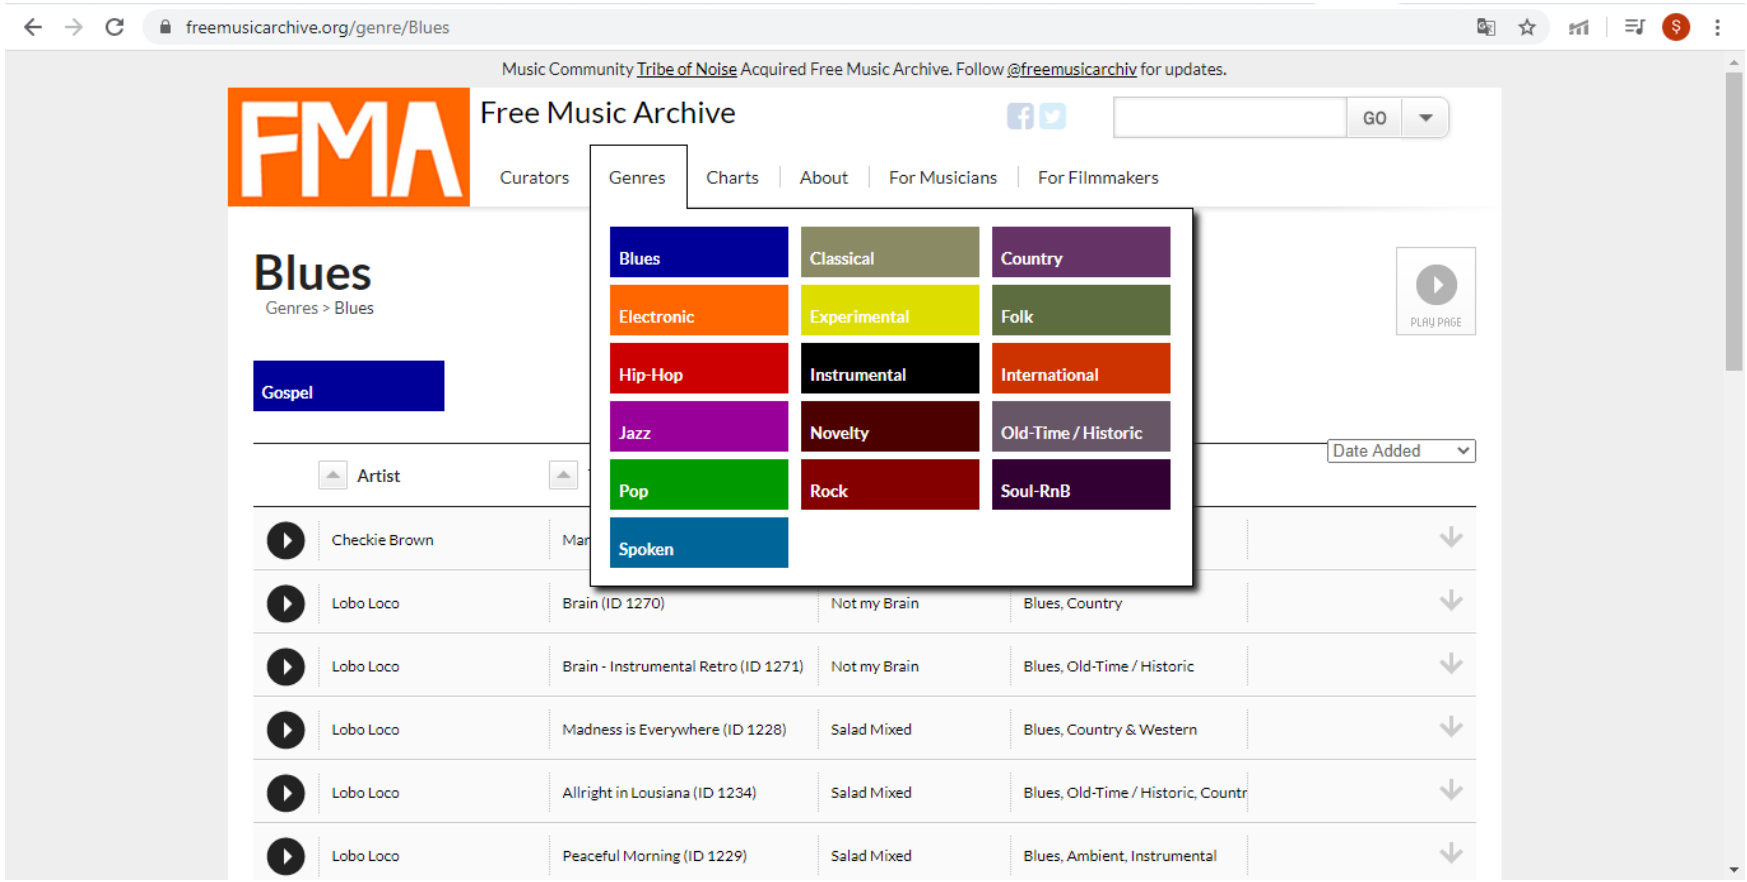

Dataset

- Veri seti her biri 30 saniye uzunluğunda 25.000 parça mp3 ve 16 türden oluşmaktadır. Tez çalışması kapsamında kullanılması için 6 farklı tür (**blues, classical, electronic, hip-hop, metal, punk**) seçilip veri seti oluşturulmuştur.

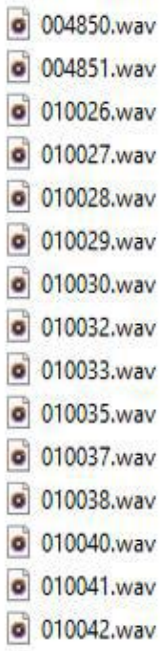

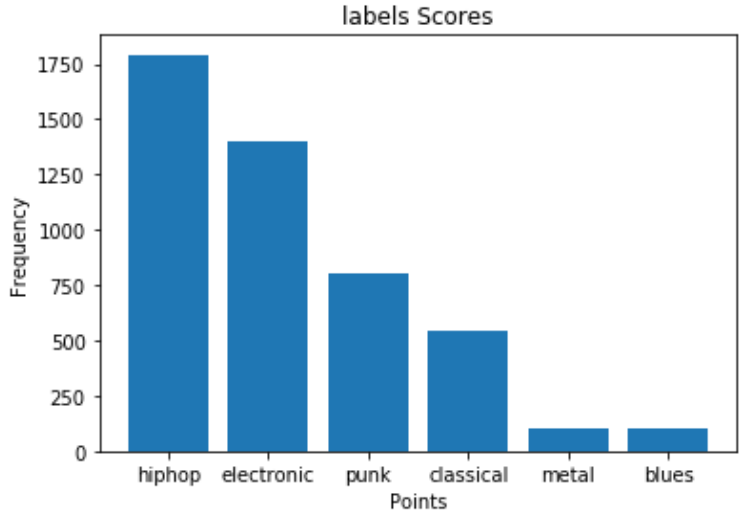

Audio Processing

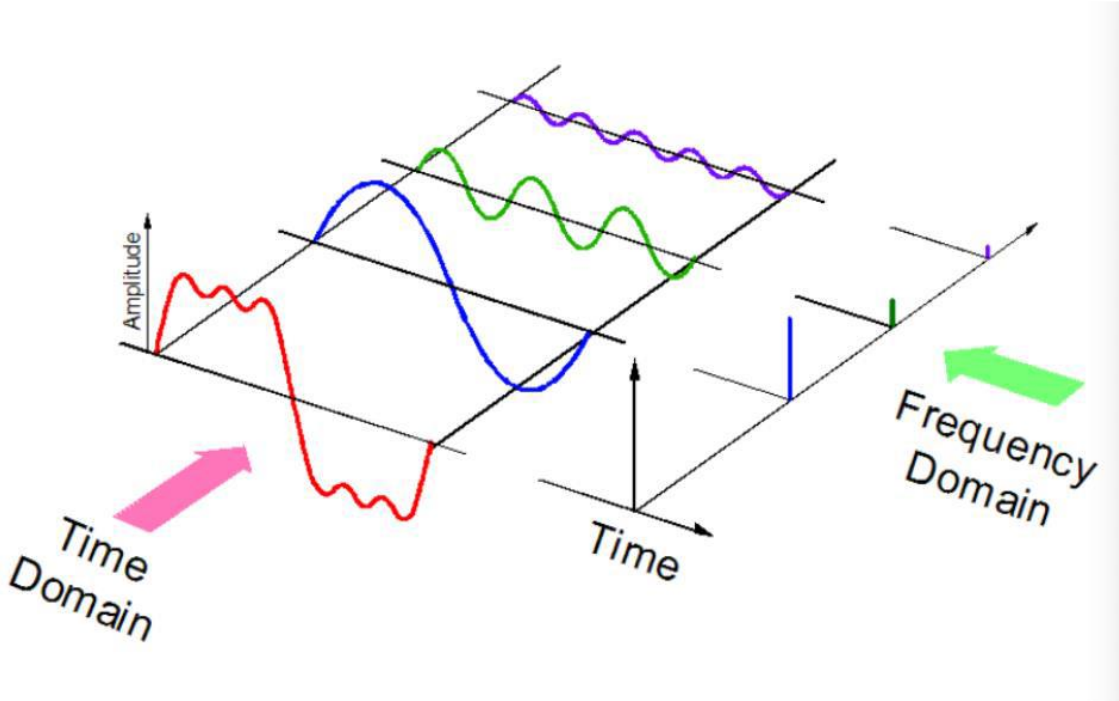

- Audio, frakans,bant genişliği desibel gibi parametrelere sahip olan bir ses sinyali şeklinde temsil edilebilir.
- Tipik bir ses sinyali, genlik ve zamanın bir fonksiyonu olarak ifade edilir.
- Python' ın librosa kütüphanesi ile ses işleme yapılmıştır.

Ses Dosyasının Yüklenmesi

Name	Type	Size	Value
ses	str	1	classical.00000.wav
sr	int	1	22050
y	float32	(661794,)	[-0.02008057 -0.01748657 0.00418091 ... 0.01934814 0.027771 0.031 ...

y: ses zaman serisi
sr: ses frekansı

Sesin Görüntülenmesi

BLUES

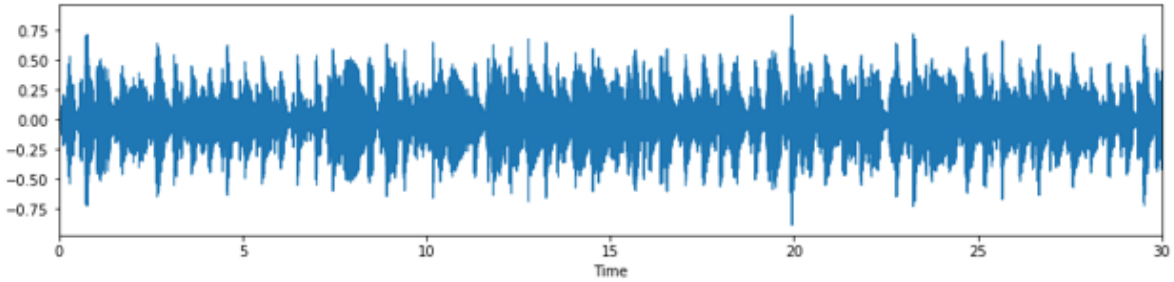

CLASSICAL

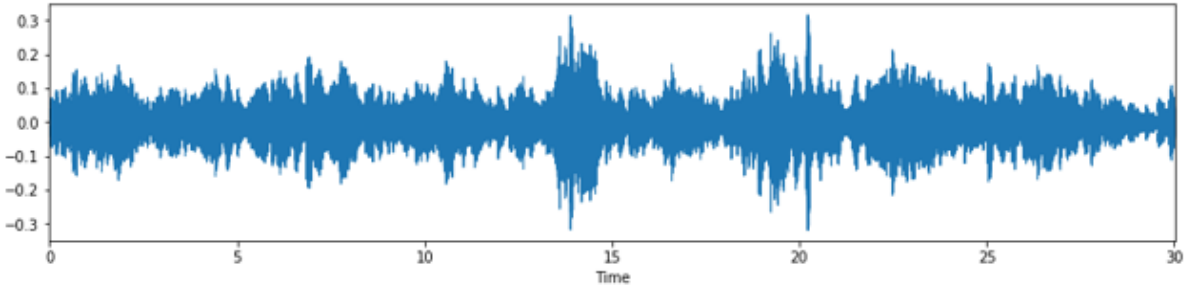

HIP-HOP

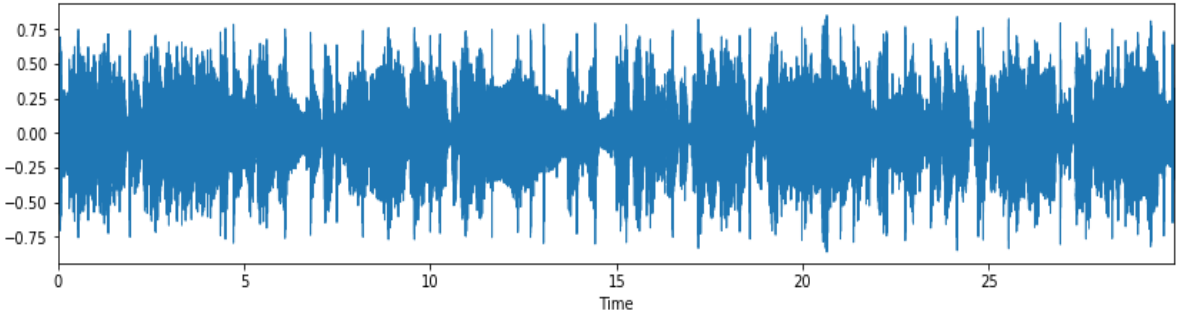

ELECTRONIC

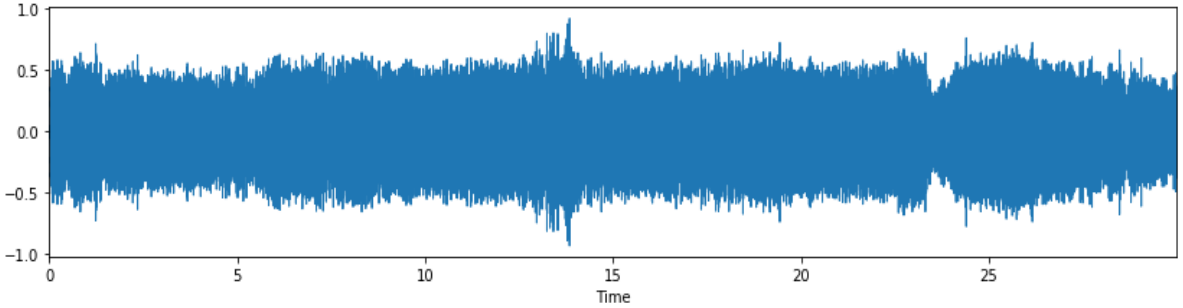

METAL

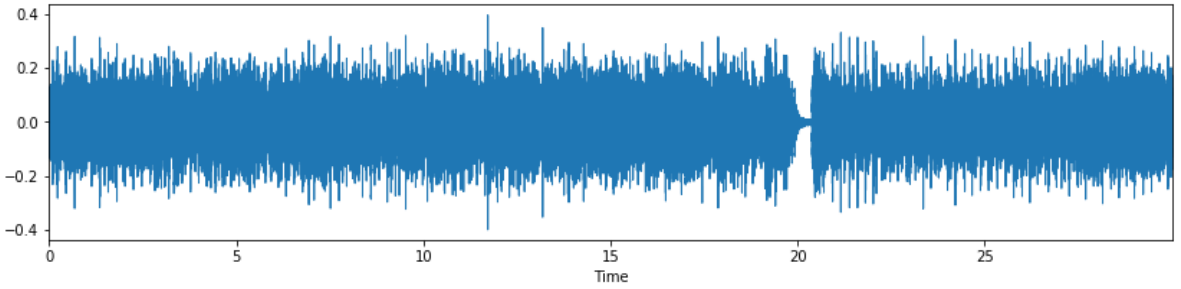

PUNK

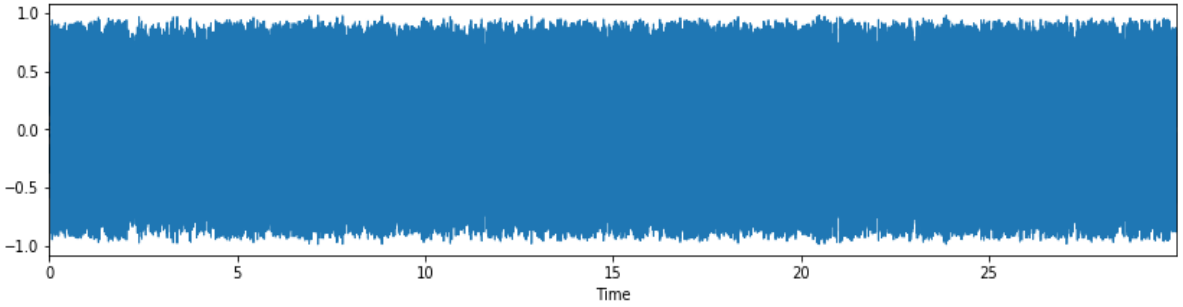

Spektogram

- Spektogram, belirli bir dalga formunda bulunan çeşitli frekanslarda bir sinyalin gücünü veya yüksekliğini temsil eden görsele verilen addır.

Dikey eksen frekansları (0-10 KHz)
Yatay eksen audionun süresini gösterir.

Classical

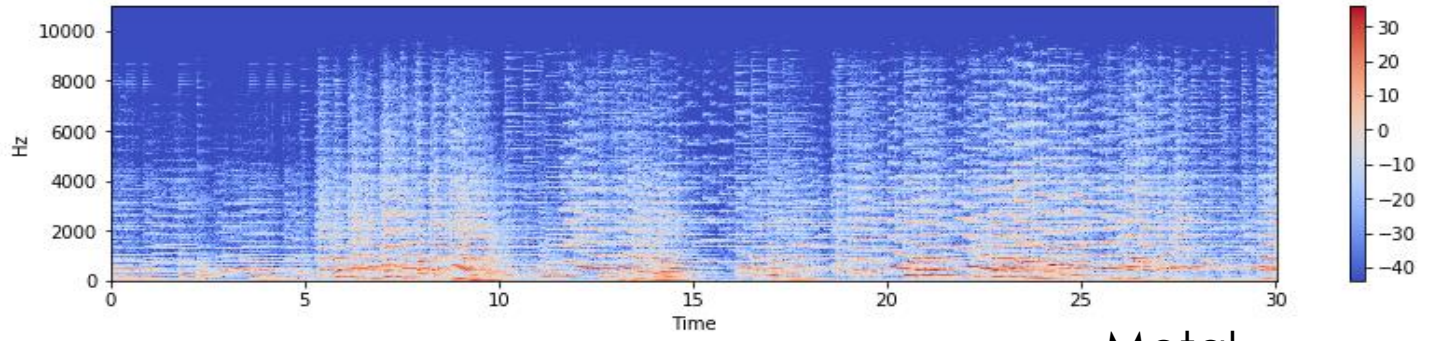

Metal

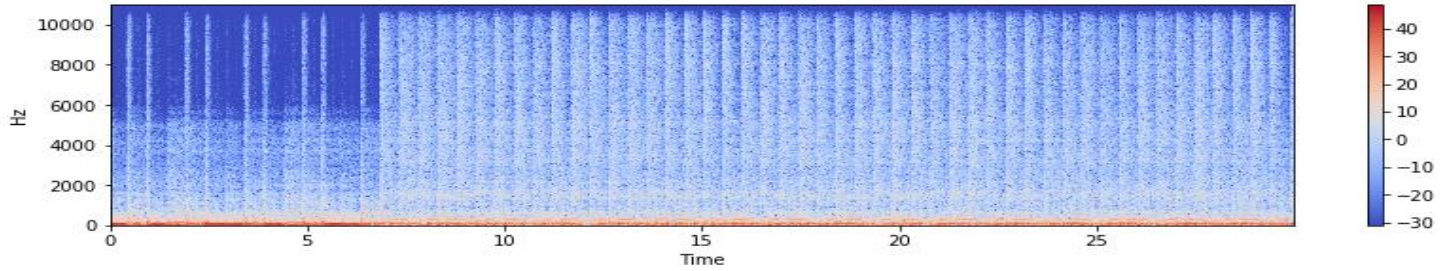

Öznitelik Çıkarımı (Feature Extraction)

- **Zero Crossing Rate**

Zero crossing rate, bir sinyal boyunca işaret değiştirme oranıdır, yani sinyalin pozitiften negatife geçişi veya geri dönme hızıdır. Bu özellik müzik bilgisi alımında yoğun bir şekilde kullanılmıştır.

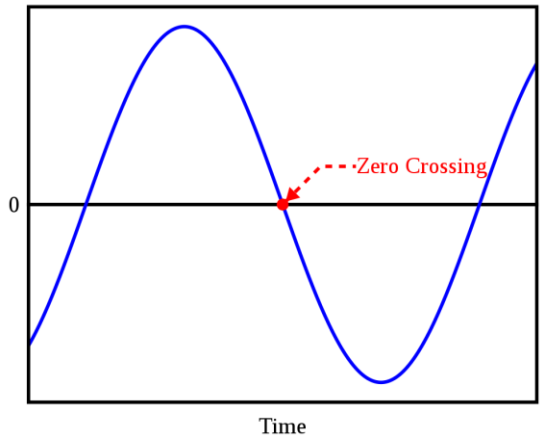

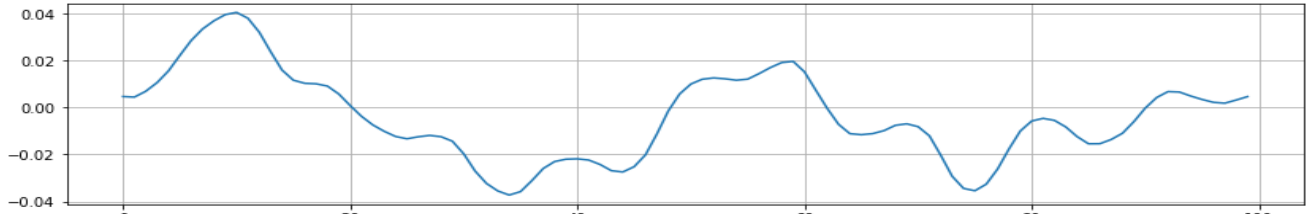

Classical (4)

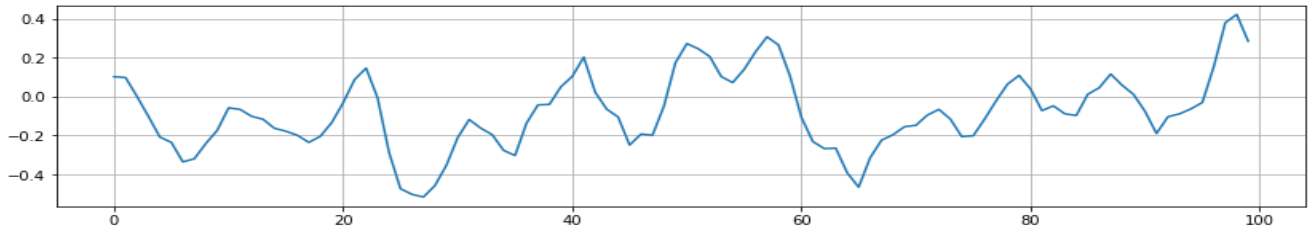

Punk (12)

- **Spectoral Centroid**

Spektorumun kütle merkezinin nerede olduğunu gösterir. Bir ses için kütle merkezinin nerede bulunduğu ve seste bulunan frekansların ağırlıklı ortalaması olarak hesaplandığını gösterir.

Classical

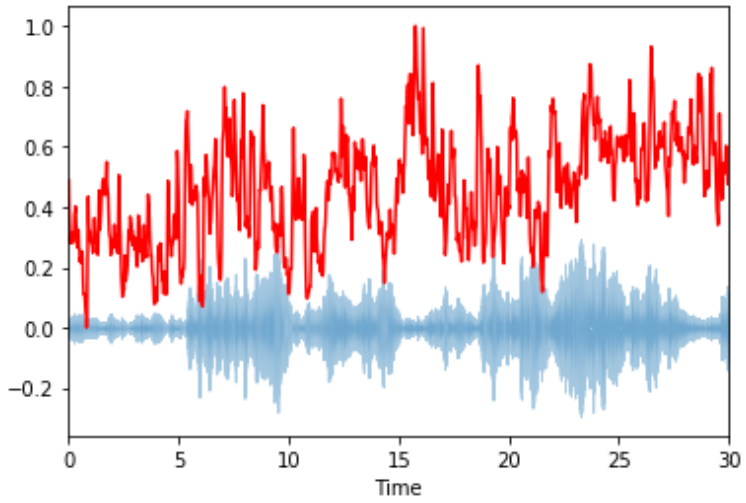

Punk

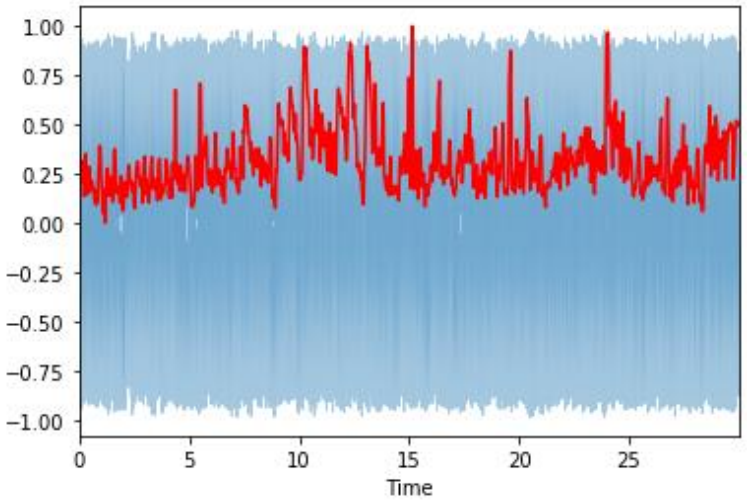

- **Spectral Rolloff**

Sinyal şeklinin ölçüsüdür. Toplam spektral enerjisinin belli bir yüzdesini temsil eder.

Classical

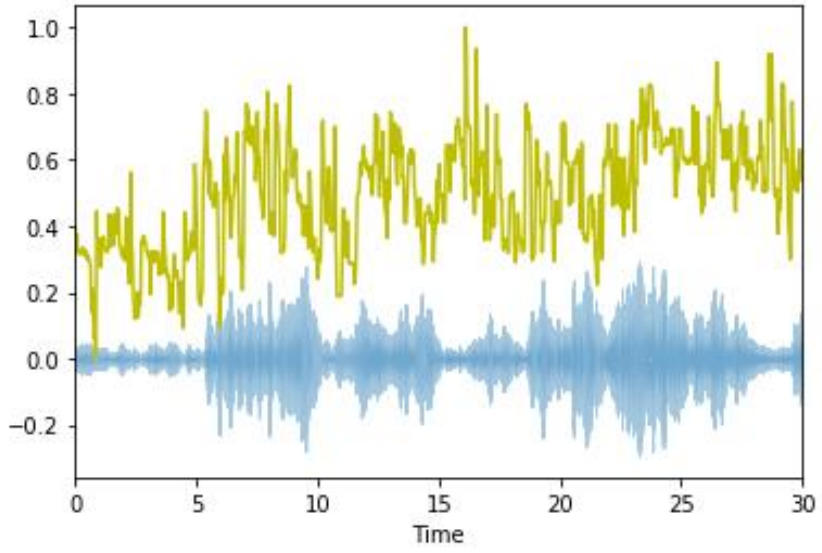

Punk

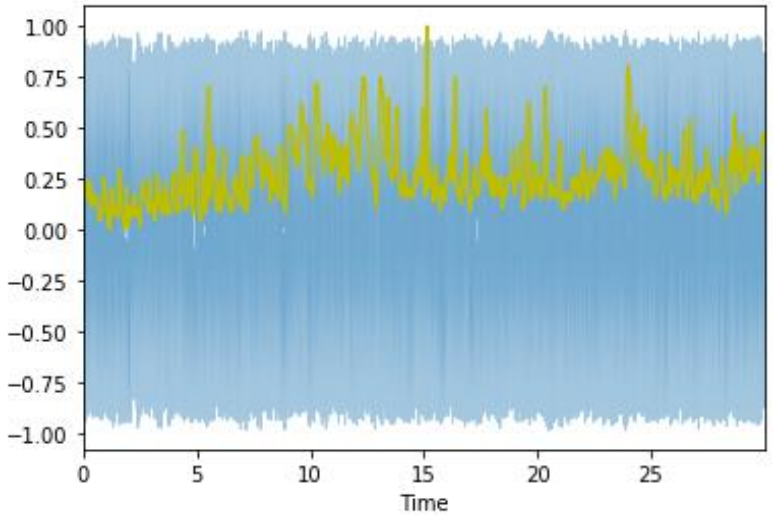

- **Mel-Frekans Kepstral Katsayıları (Mel-Frequency Cepstral Coefficients)**

Ses sinyalinin kısa zamanlı güç spektrumunun Mel ölçeği üzerindeki ifadesidir. Frekanstan Mel ölçeğine dönüşüm formülü aşağıda ki gibidir. M, mel ölçeğini f ise Frekansı belirtir.

$$M = 1125 \times \ln(1+(f \div 700))$$

Classical

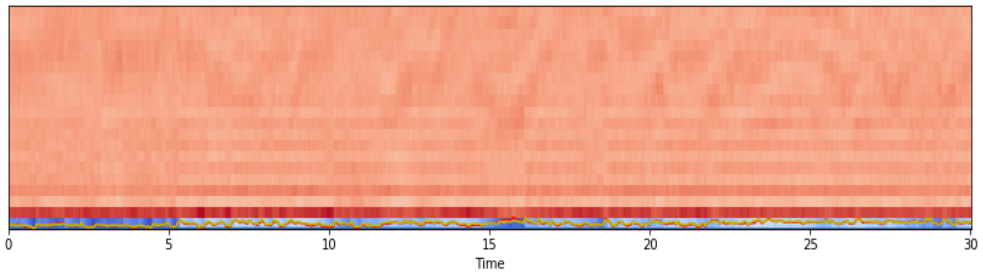

Punk

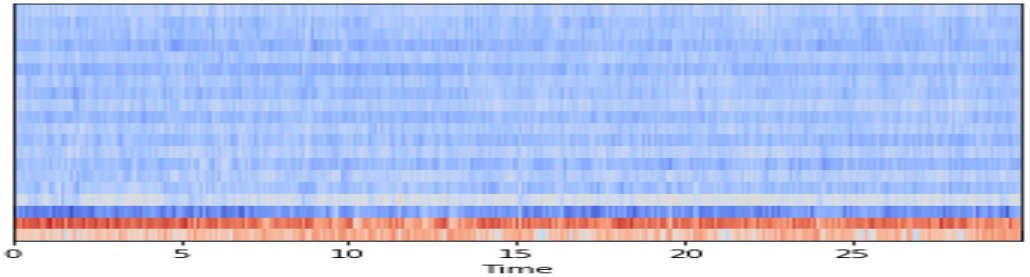

Veri inceleme adımları ve yapılan işlemler

- Eksik veri olmadığı gözlemlenmiştir.
- Veri değişken tipleri incelendiğinde filename ve class (label/sınıf) değerlerinin kategorik verileri olduğu gözlemlenmiştir. Label_Encoder işlemi uygulandı.
- Özellikler (sütunlar) arası uyuma bakmak için korelasyonn katsayısı incelenip görselleştirilmiştir.
- Kullanılmayacak öznitelikler temizlendi

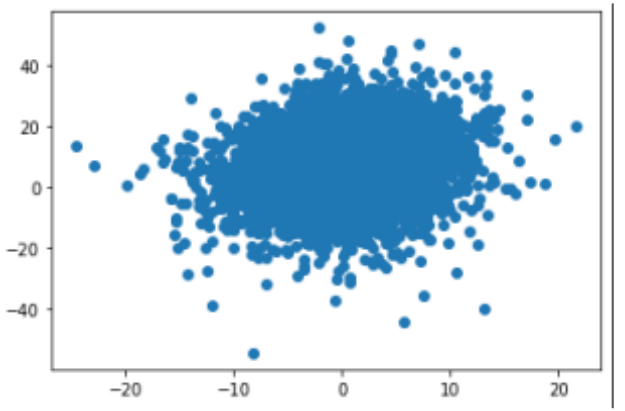

Feature Selection (Öznitelik Seçimi)

Dataframe, öznitelik isimleri ve dönüşüm uygulandıktan sonraki durumları verilmiştir.

```
In [73]: data
Out[73]:
             filename  chroma_stft      rmse  ...     mfcc19     mfcc20  label
0     blues.00000.wav     0.349943  0.130225  ...  -2.300208   1.219928  blues
1     blues.00001.wav     0.340983  0.095918  ...  -0.287431   0.531573  blues
2     blues.00002.wav     0.363603  0.175573  ...  -3.433434  -2.226821  blues
3     blues.00003.wav     0.404779  0.141191  ...  -0.619690  -3.408233  blues
4     blues.00004.wav     0.308590  0.091563  ...  -4.409333 -11.703781  blues
5     blues.00005.wav     0.302346  0.103468  ...  -3.046866  -8.115809  blues
6     blues.00006.wav     0.291308  0.141796  ...  -3.449033  -6.495511  blues
7     blues.00007.wav     0.307921  0.131785  ...  -4.693749  -8.638613  blues
8     blues.00008.wav     0.409037  0.142438  ...   3.409809  -2.698353  blues
9     blues.00009.wav     0.274009  0.081352  ...   2.891266  -4.233204  blues
10    blues.00010.wav     0.303954  0.142939  ...  -0.743599  -4.986112  blues
11    blues.00011.wav     0.367137  0.065713  ...   1.836151  -4.897420  blues
12    blues.00012.wav     0.269320  0.119072  ...  -1.418707  -5.932607  blues
...               ...          ...       ...  ...        ...        ...    ...
4725      149940.wav     0.532339  0.176460  ...  -1.704041   1.504423  punk
4726      150479.wav     0.476088  0.361779  ...  -4.396061   0.628166  punk
4727      150481.wav     0.402240  0.374054  ...  -5.500439   2.192954  punk
4728      150482.wav     0.430244  0.387793  ... -10.172757   6.198986  punk
4729      151964.wav     0.473416  0.230945  ...  -4.207032   0.603890  punk
4730      151965.wav     0.495777  0.227619  ...  -6.927705  -3.049185  punk
4731      155314.wav     0.421965  0.141610  ...  -8.734600  -5.078706  punk

[4732 rows x 28 columns]
```

```
filename              object
chroma_stft          float64
rmse                 float64
spectral_centroid    float64
spectral_bandwidth   float64
rolloff              float64
zero_crossing_rate   float64
mfcc1                float64
mfcc2                float64
mfcc3                float64
mfcc4                float64
mfcc5                float64
mfcc6                float64
mfcc7                float64
mfcc8                float64
mfcc9                float64
mfcc10               float64
mfcc11               float64
mfcc12               float64
mfcc13               float64
mfcc14               float64
mfcc15               float64
mfcc16               float64
mfcc17               float64
mfcc18               float64
mfcc19               float64
mfcc20               float64
label                 object
```

```
In [83]: data.dtypes
Out[83]:
chroma_stft          float64
rmse                 float64
spectral_centroid    float64
spectral_bandwidth   float64
rolloff              float64
zero_crossing_rate   float64
mfcc1                float64
mfcc3                float64
mfcc4                float64
mfcc5                float64
mfcc6                float64
mfcc7                float64
mfcc8                float64
mfcc9                float64
mfcc10               float64
mfcc11               float64
mfcc12               float64
mfcc13               float64
mfcc14               float64
mfcc15               float64
mfcc16               float64
mfcc17               float64
mfcc18               float64
mfcc19               float64
mfcc20               float64
label                  int32
```

```
In [91]: data.isna().sum().sum()
Out[91]: 0
```

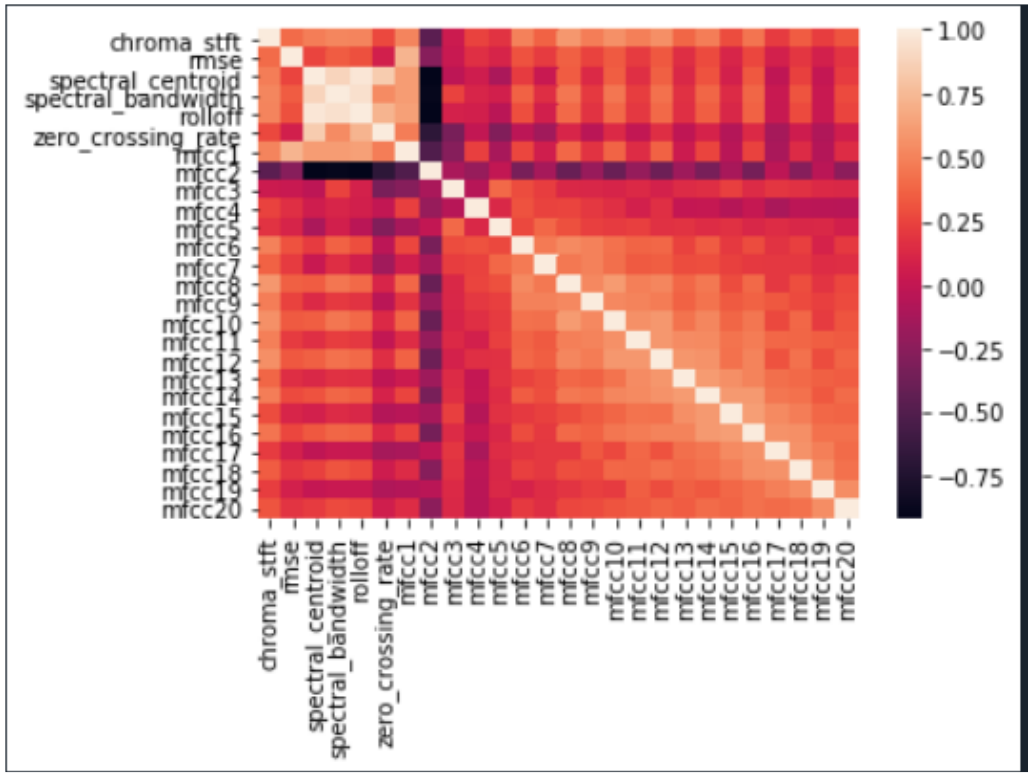

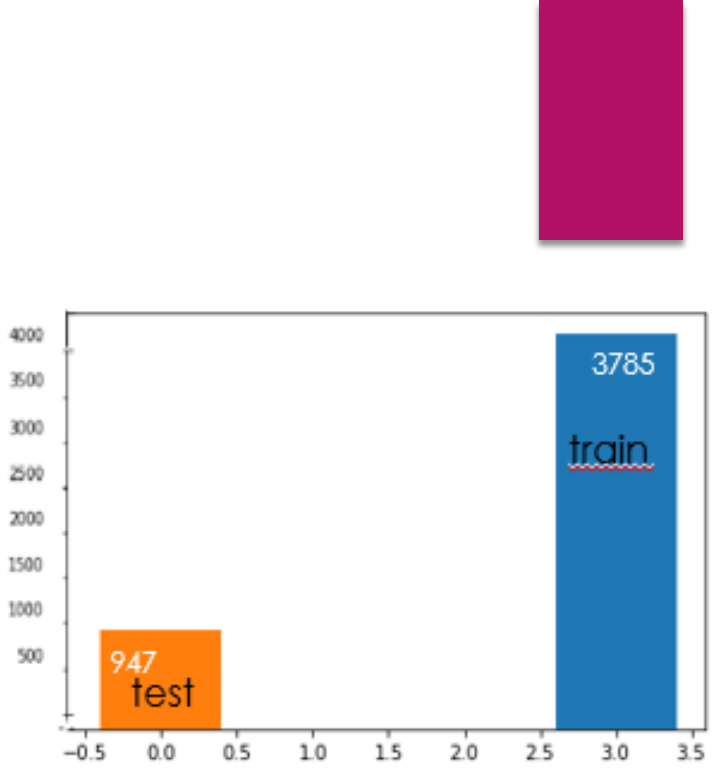

Öznitelikler arası korelasyon matrisi

data - DataFrame

Index	chroma_stft	rmse	spectral_centroid	spectral_bandwidth	rolloff	zero_crossing_rate	mfcc1	mfcc2	mfcc3	mfcc4	mfcc5	mfcc6	mfcc7	mfcc8	mfcc9	mfcc10	mfcc11	mfcc12	mfcc13
0	0.349943	0.130225	1784.42	2002.65	3806.49	0.0830664	-113.597	121.557	-19.1588	42.351	-6.37646	18.6189	-13.6979	15.3446	-12.2853	10.9805	-8.32432	8.81067	-3.66737
1	0.340983	0.0959184	1529.84	2038.62	3548.82	0.0560443	-207.557	124.007	8.93056	35.8747	2.91604	21.5237	-8.5547	23.3587	-10.1036	11.9037	-5.56039	5.3768	-2.23912
2	0.363603	0.175573	1552.48	1747.17	3040.51	0.0763007	-90.7544	140.46	-29.11	31.689	-13.987	25.7548	-13.6496	11.6293	-11.7806	9.70644	-13.1231	5.78926	-8.90522
3	0.404779	0.141191	1070.12	1596.33	2185.03	0.0333089	-199.431	150.099	5.64759	26.8719	1.75446	14.2383	-4.83088	9.29797	-0.757741	8.14901	-3.19631	6.08768	-2.47642
4	0.30859	0.0915632	1835.49	1748.36	3580.95	0.1015	-160.266	126.199	-35.6054	22.1533	-32.4893	10.8645	-23.3579	0.503117	-11.8058	1.2068	-13.0838	-2.80638	-6.93412
5	0.302346	0.103468	1831.94	1729.48	3480.94	0.0940399	-177.869	118.197	-17.5507	30.7586	-21.7427	11.9038	-20.7342	3.1806	-8.58348	-0.936488	-11.7763	-2.42061	-9.33936

Modelleme yapılmadan önce veri setinin son hali

Sınıflandırma ve Performans Değerlendirmesi

▶ KNN (en yakın komşu) ile modelleme

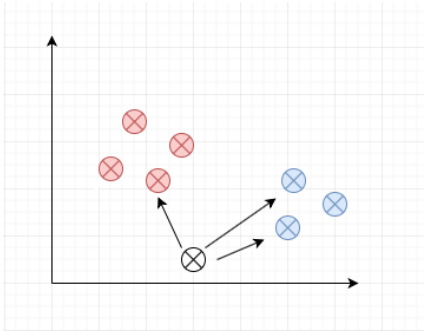

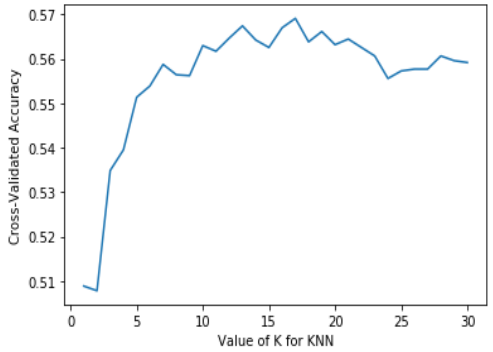


```
In [12]: runcell('KNN', 'C:/Users/TOSHIBA/Desktop/tk/train.p
Accuracy: 0.5755015839493136
knn:              precision    recall  f1-score   support

           0       0.43      0.21      0.29        14
           1       0.81      0.88      0.84       108
           2       0.50      0.44      0.46       287
           3       0.57      0.63      0.60       367
           4       0.63      0.63      0.63        19
           5       0.53      0.51      0.52       152

    accuracy                           0.58       947
   macro avg       0.58      0.55      0.56       947
weighted avg       0.57      0.58      0.57       947
```

▶ Decision Tree ile modelleme

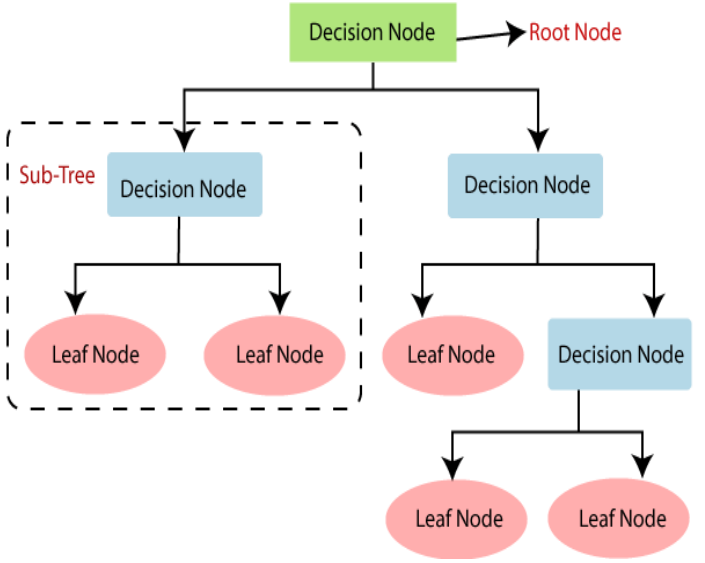


```
In [13]: runcell('Decision Tree', 'C:/Users/TOSHIBA/Desktop
Accuracy: 0.6187961985216474
Decision Tree
              precision    recall  f1-score   support

           0       0.35      0.43      0.39        14
           1       0.83      0.83      0.83       108
           2       0.53      0.54      0.54       287
           3       0.62      0.57      0.60       367
           4       0.78      0.74      0.76        19
           5       0.64      0.72      0.67       152

    accuracy                           0.62       947
   macro avg       0.62      0.64      0.63       947
weighted avg       0.62      0.62      0.62       947
```

Random Forest ile modelleme

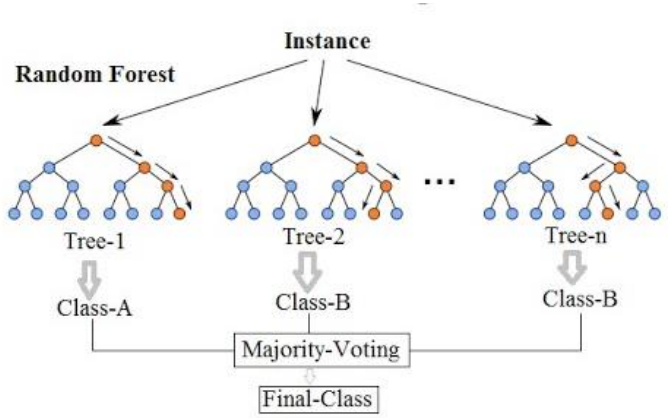


```
In [40]: runfile('C:/Users/TOSHIBA/Desktop/tk/train.py', wo
0.7624076029567054
Random Forest:
              precision    recall  f1-score   support

           0       0.85      0.79      0.81        14
           1       0.93      0.92      0.93       103
           2       0.72      0.64      0.68       286
           3       0.73      0.81      0.77       359
           4       0.94      0.76      0.84        21
           5       0.79      0.76      0.77       164

    accuracy                           0.76       947
   macro avg       0.83      0.78      0.80       947
weighted avg       0.76      0.76      0.76       947
```

Naive Bayes ile modelleme

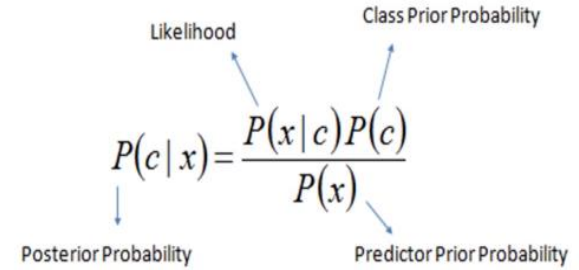

$$P(c|X) = P(x_1|c) \times P(x_2|c) \times \cdots \times P(x_n|c) \times P(c)$$

```
In [15]: runcell('Naive Bayes', 'C:/Users/TOSHIBA/Desktop/t
Accuracy: 0.5966209081309398
GaussianNB
              precision    recall  f1-score   support

           0       0.23      0.36      0.28        14
           1       0.74      0.92      0.82       108
           2       0.58      0.24      0.34       287
           3       0.59      0.69      0.63       367
           4       0.57      0.89      0.69        19
           5       0.58      0.80      0.67       152

    accuracy                           0.60       947
   macro avg       0.55      0.65      0.57       947
weighted avg       0.59      0.60      0.57       947
```

Sonuçların değerlendirilmesi ve öneri sistemi için en iyi model seçimi

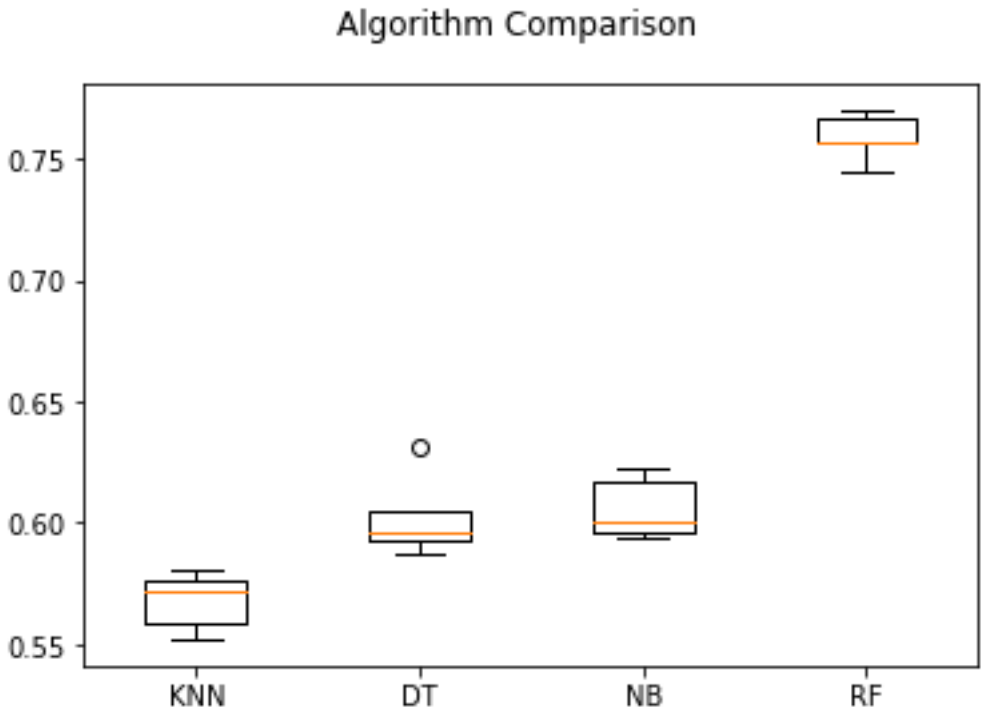

Recommendation (Öneri) Sistemi

- Genellikle Tavsiye Sistemleri olarak adlandırılan, büyük bir bilgi tabanından faydalı bilgileri filtreleyerek kullanıcıya en alakalı ve doğru öğeleri sunmayı amaçlayan bir algoritmalardır. Öneri motorları, tüketicilerin seçimlerini öğrenerek veri setindeki veri modellerini keşfeder ve onların ihtiyaçları ve ilgileriyle ilişkili sonuçlar üretir.

Collaborative (İşbirlikçi) Filtreleme

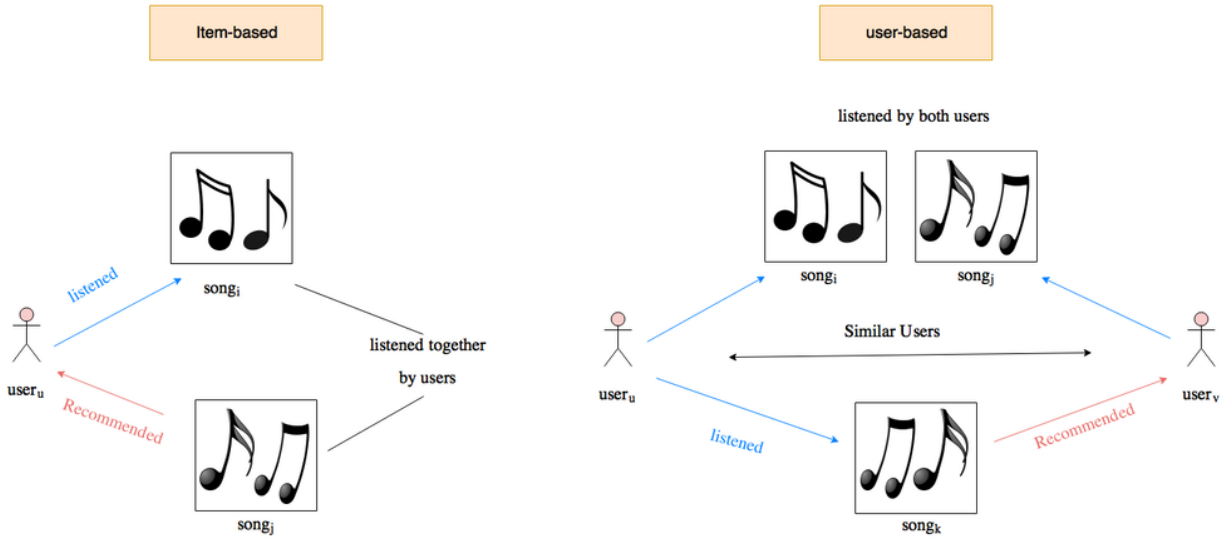

Content Based (İçerik Tabanlı) Filtreleme

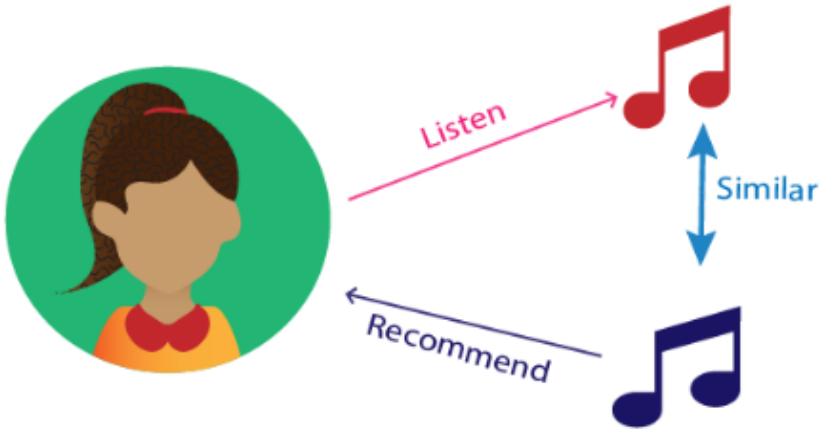

Seçilen müziğin diğer müziklerin öznitelik değerleri ile arasında ki ilişkinin anlaşılabilmesi için benzerlik fonksiyonu kullanılmıştır.

Kosinüs Benzerliği (Cosine Similarty)

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2}\sqrt{\sum_{i=1}^{n} B_i^2}},$$

Kosinüs benzerliği, bir ürün uzayının iki vektörü arasındaki benzerliği ölçer. İki vektör arasındaki açının kosinüsü ile ölçülür ve iki vektörün aynı yönü gösterip göstermediğini belirler

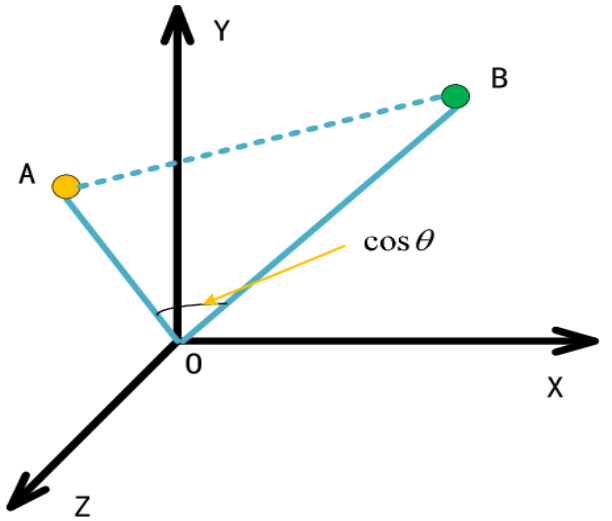

Önerilen Müzikler

Benzerlik oranları

cos_sim - NumPy array

	0
0	0.998027
1	0.997303
2	0.998289
3	0.991826
4	0.998096
5	0.998417
6	0.99886
7	0.9994
8	0.997788
9	0.998376
10	0.999584
11	0.998261
12	0.999519

Format Resize Background

Önerilen ilk 5 benzer müziğin listesi

oneri - DataFrame

Index	simila	adi	label
105	0.999977	classical.00005.wav	1
383	0.999941	055953.wav	1
388	0.999936	055958.wav	1
4657	0.999916	131166.wav	5
110	0.999916	classical.00010.wav	1

SONUÇ (CONCLUSION)

Karşılaşılan Problemler

10 farklı tür ile çalışıldığında ;

Veri setinde ki türler arası boyut farklı

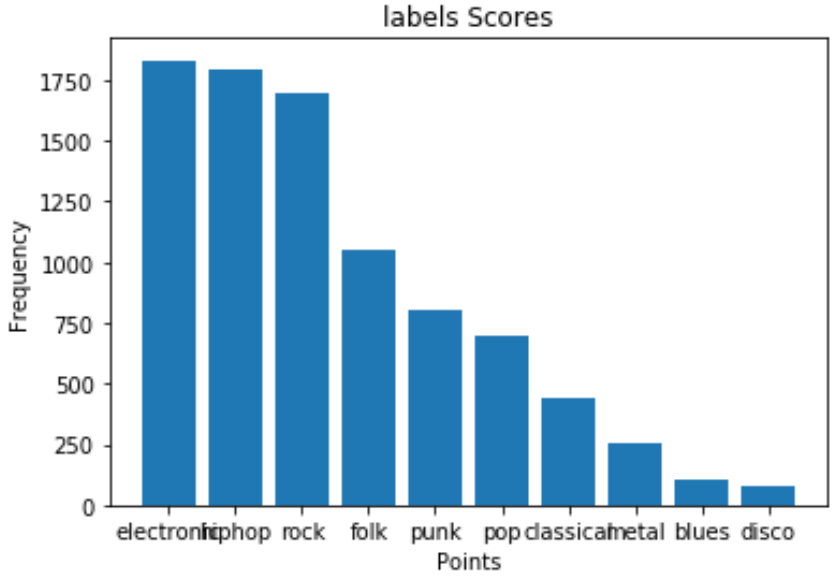

Düşük accuracy değerleri

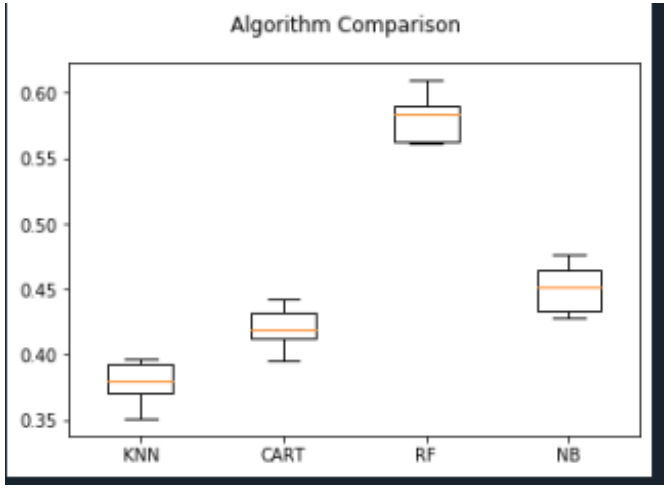

Underfitting durumu

Random Forest:

	precision	recall	f1-score	support
0	1.00	0.67	0.80	15
1	0.78	0.86	0.82	94
2	0.00	0.00	0.00	15
3	0.48	0.59	0.53	336
4	0.64	0.77	0.70	211
5	0.54	0.60	0.57	360
6	0.64	0.16	0.26	55
7	0.19	0.03	0.06	151
8	0.62	0.37	0.46	171
9	0.53	0.67	0.59	338
accuracy			0.55	1746
macro avg	0.54	0.47	0.48	1746
weighted avg	0.53	0.55	0.53	1746

Kullanıcı Ara Yüzü

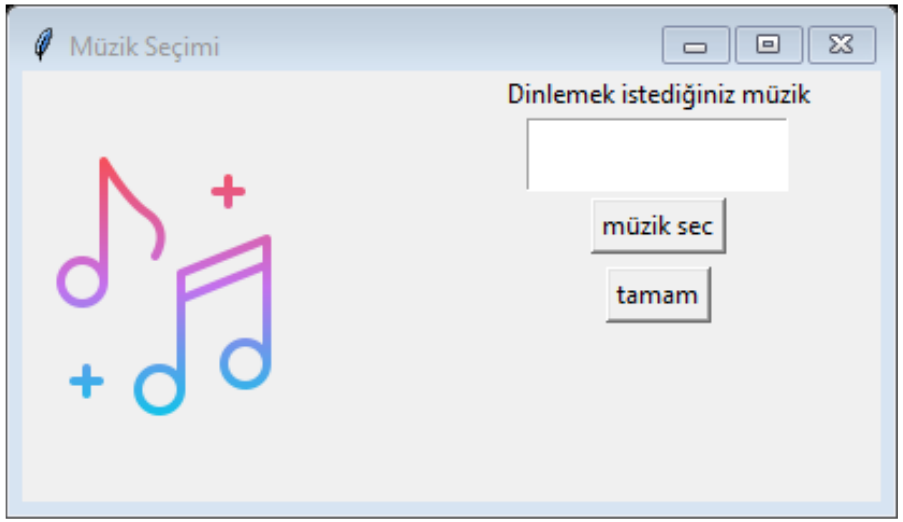

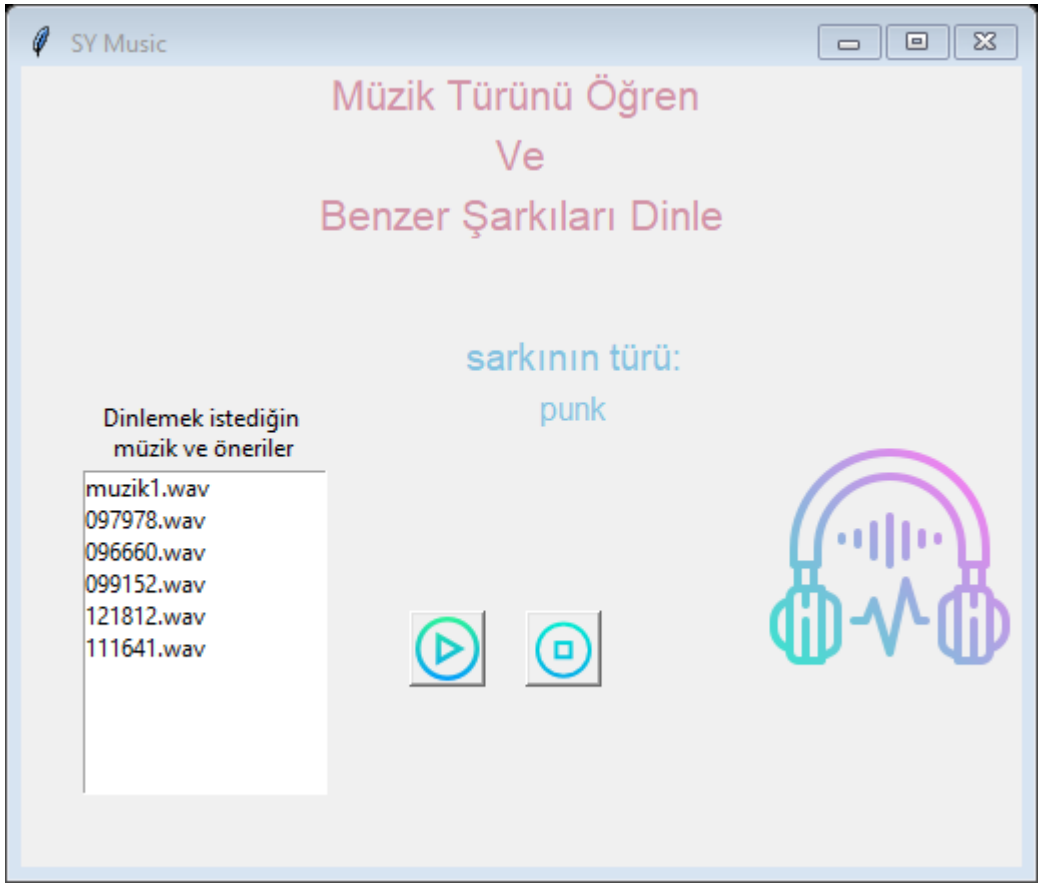

Kullanıcı ara yüzü videolu gösterim

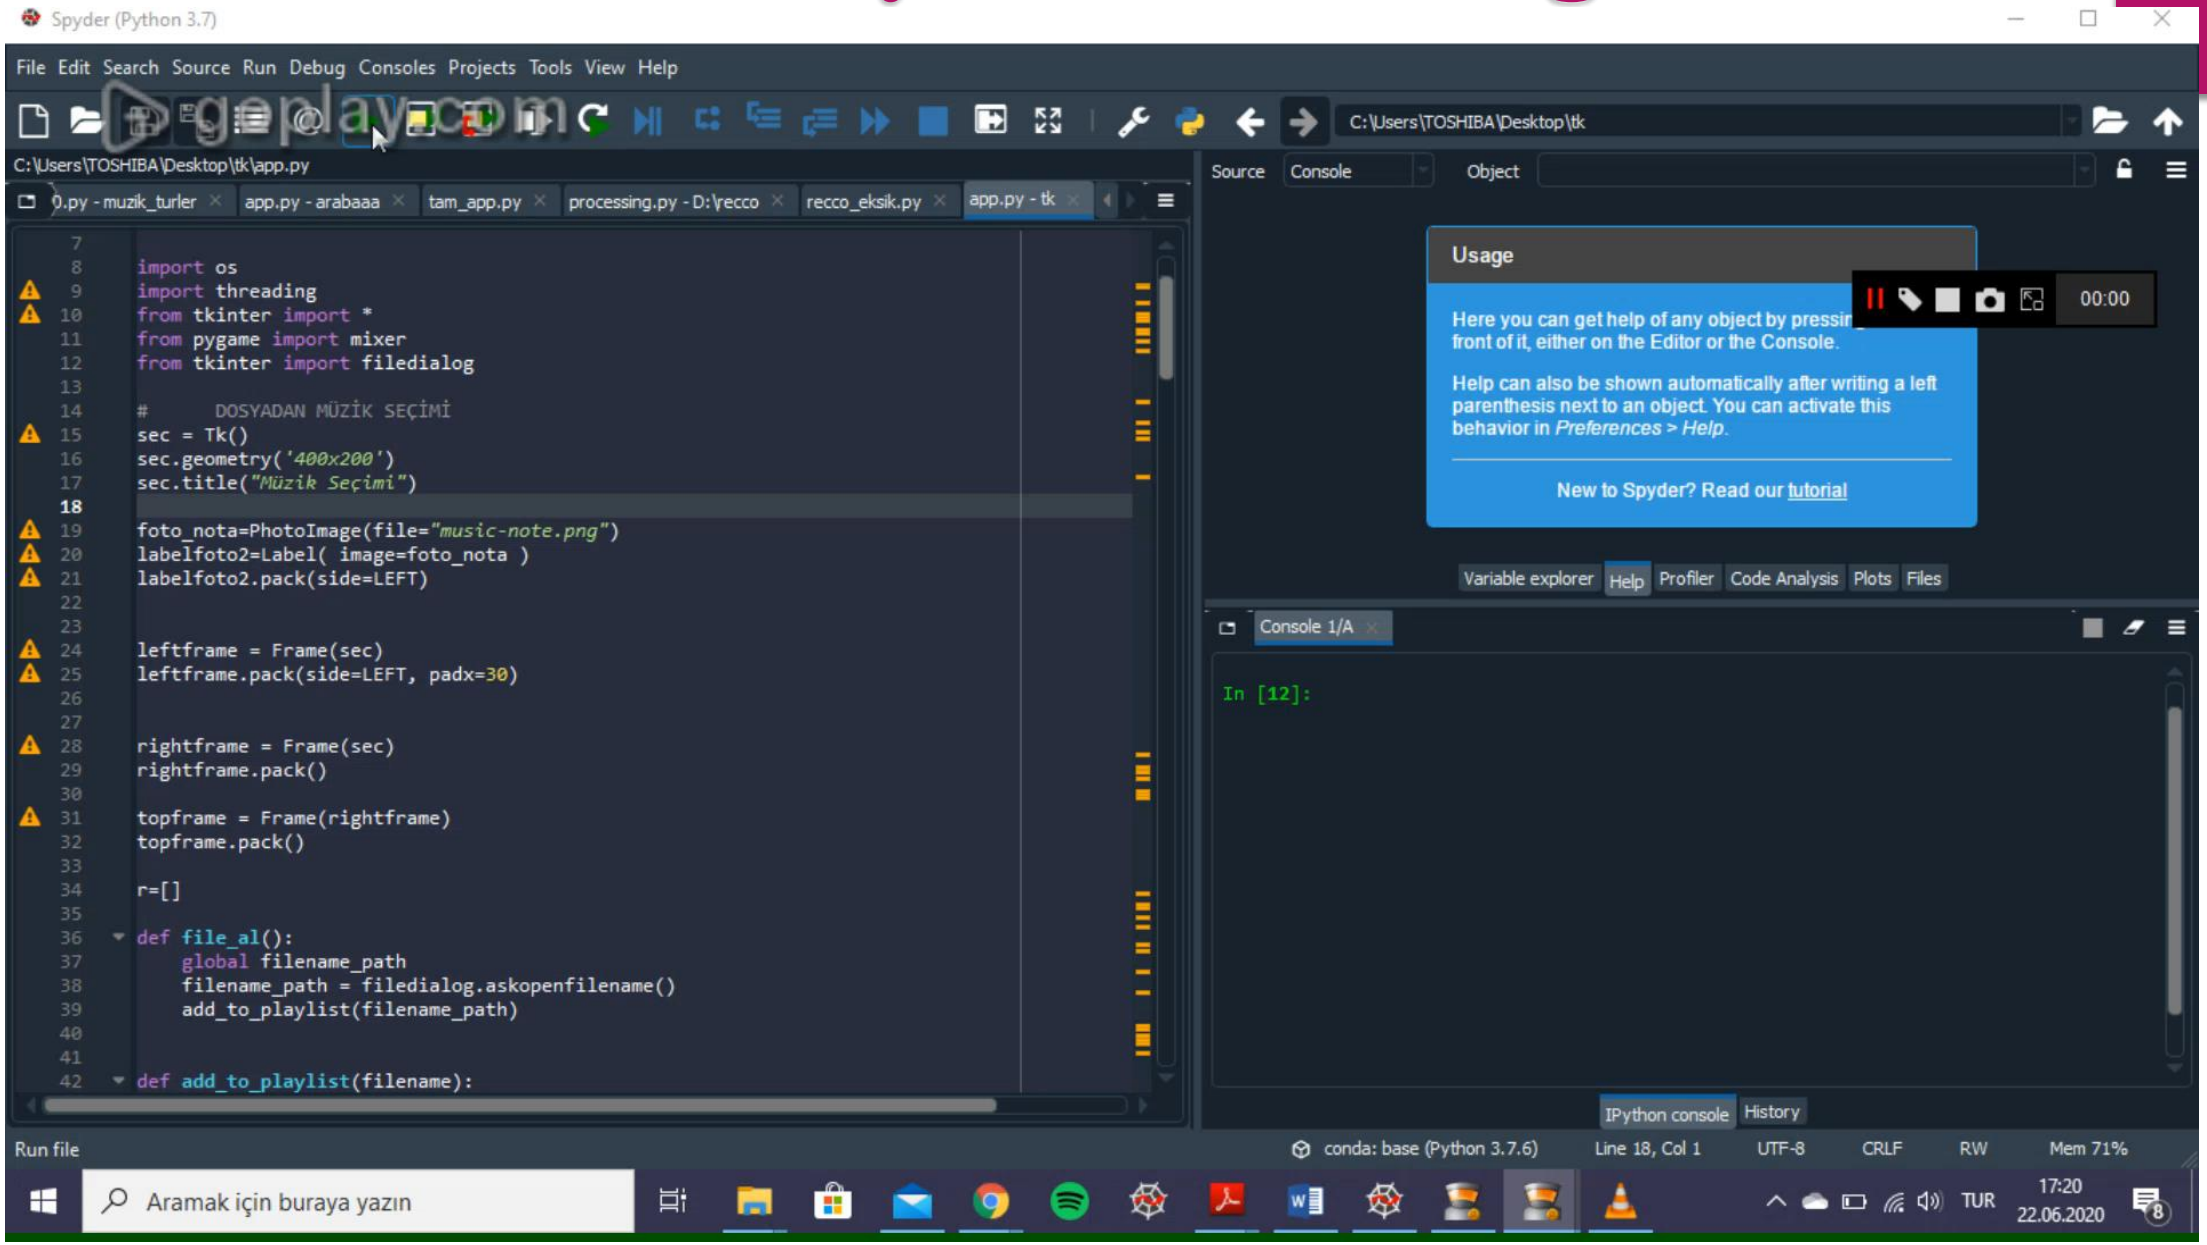

Teşekkür Ederim..